

Evaluación del impacto de la computación cuántica en la clasificación de imágenes mediante modelos de CNN

Johan Arbey Vargas Mejía
C.C. 1152195956 de Medellín

Entregable II

Especialización en Analítica y Ciencia de Datos
Departamento de Ingeniería de Sistemas
Universidad de Antioquia, Colombia

RESUMEN

El problema de comparar computación clásica y cuántica en el contexto de redes neuronales convolucionales (CNNs) surge de la necesidad de buscar nuevas herramientas computacionales que permitan procesar y analizar grandes cantidades de datos de manera más eficiente y precisa. A medida que el volumen de datos disponible sigue creciendo exponencialmente, las técnicas de deep learning se han convertido en una herramienta clave para el análisis y la toma de decisiones basadas en datos.

Aunque las CNNs han demostrado ser muy efectivas en muchos casos, todavía hay limitaciones en su capacidad para manejar grandes cantidades de datos de manera eficiente. En particular, la naturaleza secuencial de los cálculos de las CNNs significa que su rendimiento se ve limitado por la velocidad de los procesadores clásicos convencionales.

La computación cuántica se presenta como una posible solución para mejorar el rendimiento de las CNNs, gracias a su capacidad para procesar grandes cantidades de datos de manera simultánea. Además, la naturaleza probabilística de la computación cuántica podría ser útil para algunos problemas de clasificación, especialmente en situaciones en las que hay una gran cantidad de ruido en los datos.

En resumen, el problema de comparar computación clásica y cuántica en el contexto de CNNs se refiere a la necesidad de investigar y evaluar el rendimiento de ambos enfoques en la clasificación de imágenes, con el objetivo de determinar si la computación cuántica puede ofrecer mejoras significativas en la eficiencia y precisión de la clasificación de imágenes.

Palabras clave: Convolución, Cuántica, clásica.

Comprensión del problema

El objetivo de este trabajo de deep learning es comparar el rendimiento de redes neuronales convolucionales clásicas y cuánticas en la tarea de clasificación de imágenes utilizando el dataset CIFAR10.

Procedimiento:

Preparación de los datos: Se realizará la carga y preprocesamiento del dataset CIFAR10. Esto implica dividir el conjunto de datos en conjuntos de entrenamiento y prueba, y realizar transformaciones como normalización y redimensionamiento de las imágenes.

Implementación de redes neuronales convolucionales clásicas: Se construirá y entrenará una red neuronal convolucional clásica utilizando una biblioteca de deep learning como TensorFlow o PyTorch. Esta red se diseñará con capas convolucionales, capas de pooling y capas totalmente conectadas, y se entrenará utilizando el conjunto de entrenamiento CIFAR10.

Implementación de redes neuronales convolucionales cuánticas: Se explorará el uso de redes neuronales cuánticas para la clasificación de imágenes. Esto implica la codificación de los datos de entrada en qubits y el diseño de capas de procesamiento cuántico. La implementación se realizará utilizando Qiskit.

Entrenamiento y evaluación de las redes: Se entrenarán tanto la red convolucional clásica como la red convolucional cuántica utilizando el conjunto de entrenamiento CIFAR10. Se medirá el rendimiento de ambas redes utilizando el conjunto de prueba y se compararán los resultados.

Campo de aplicación:

El campo de aplicación de este trabajo abarca la clasificación de imágenes utilizando técnicas de deep learning. El uso de redes neuronales convolucionales clásicas ha demostrado ser efectivo en tareas de visión por computadora, como la clasificación de imágenes en conjuntos de datos como CIFAR10. Sin embargo, el desarrollo de redes neuronales cuánticas ofrece la posibilidad

de aprovechar las propiedades únicas de la computación cuántica para mejorar el rendimiento en ciertos problemas. Este estudio comparativo ayudará a comprender las fortalezas y limitaciones de las redes neuronales cuánticas en la clasificación de imágenes y su potencial aplicación en problemas de visión por computadora.

Estado del arte

- Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). ImageNet Classification with Deep Convolutional Neural Networks. En Advances in Neural Information Processing Systems 25 (NIPS 2012).

Recuperado de:

https://papers.nips.cc/paper_files/paper/2012/file/c399862d3b9d6b76c8436e924a68c45b-Paper.pdf

En este estudio, se entrenó una red neuronal convolucional profunda y grande para clasificar 1.2 millones de imágenes de alta resolución en el concurso ImageNet LSVRC-2010 en 1000 clases diferentes. En los datos de prueba, se lograron tasas de error top-1 y top-5 de 37.5% y 17.0%, respectivamente, lo cual es considerablemente mejor que los resultados anteriores del estado del arte. La red neuronal, que cuenta con 60 millones de parámetros y 650,000 neuronas, consta de cinco capas convolucionales, algunas de las cuales están seguidas por capas de max-pooling, y tres capas completamente conectadas con una función softmax de 1000 vías al final. Para acelerar el entrenamiento, se utilizaron neuronas no saturadas y una implementación muy eficiente en GPU de la operación de convolución. Para reducir el sobreajuste en las capas completamente conectadas, se empleó un método de regularización recientemente desarrollado llamado "dropout", el cual resultó ser muy efectivo. Además, se presentó una variante de este modelo en la competición ILSVRC-2012, logrando una tasa de error top-5 ganadora de 15.3%, en comparación con el 26.2% logrado por la segunda mejor entrada.

- Akwasi D Akwaboah (2019) Convolutional Neural Network for CIFAR-10 Dataset Image Classification.

Recuperado de:

https://www.researchgate.net/publication/337240963_Convolutional_Neural_Network_for_CIFAR-10_Dataset_Image_Classification

En este informe se presenta un enfoque de red neuronal convolucional (CNN) para clasificar conjuntos de datos CIFAR-10. A diferencia de las redes neuronales tradicionales, este enfoque evita el tedioso proceso de ingeniería de características

y ha demostrado lograr un rendimiento mejorado. Se utilizaron filtros y capas de pooling aprendibles para extraer características subyacentes de las imágenes. Además, se aplicaron técnicas como dropout, regularización y variación en las estrategias de convolución para reducir el sobreajuste y aumentar la precisión en la validación y las pruebas. Se logró una mejor precisión en las pruebas con una reducción en el sobreajuste al utilizar una red más profunda.

- Jing, Y., Li, X., Yang, Y., Wu, C., Fu, W., Hu, W., Li, Y., & Xu, H. (2021). RGB Image Classification with Quantum Convolutional Ansatz. arXiv preprint arXiv:2107.11099v2 [quant-ph].

Recuperado de:

<https://arxiv.org/pdf/2107.11099.pdf>

En este artículo, se aborda el desafío de implementar redes neuronales someras en dispositivos cuánticos de Escala Intermedia Ruidosos (NISQ, por sus siglas en inglés), que están experimentando un rápido crecimiento en cuanto al número de qubits y a los tiempos de coherencia. Se han propuesto varios ansatz de circuitos cuánticos (convolucionales) para tareas de clasificación de imágenes en escala de grises, con resultados empíricos prometedores. Sin embargo, al aplicar estos ansatz en imágenes RGB, la información intra-canal que es útil para las tareas de visión no se extrae de manera efectiva. En este trabajo, se proponen dos tipos de ansatz de circuitos cuánticos para simular operaciones de convolución en imágenes RGB, que difieren en la forma en que se extrae la información entre canales y dentro de cada canal. Hasta donde sabemos, este es el primer trabajo que presenta un circuito cuántico de convolución para tratar imágenes RGB de manera efectiva, logrando una mayor precisión en las pruebas en comparación con las CNN clásicas puramente clásicas. También se investiga la relación entre el tamaño del ansatz de circuito cuántico y la capacidad de aprendizaje de la red neuronal convolucional híbrida cuántico-clásica. A través de experimentos basados en los conjuntos de datos CIFAR-10 y MNIST, se demuestra que un mayor tamaño del ansatz de circuito cuántico mejora el rendimiento predictivo en tareas de clasificación multiclase, lo que proporciona información útil para el desarrollo de algoritmos cuánticos a corto plazo.

Entrenamiento y evaluación de modelos

Inicialmente se ejecuta el modelo clásico, para ello:

1. Se crea un modelo secuencial, que es una pila lineal de capas de red neuronal.

2. Se agregan capas convolucionales para extraer características de las imágenes. Las capas convolucionales utilizan filtros para aplicar operaciones de convolución en las imágenes.
3. Después de cada capa convolucional, se utiliza una función de activación ReLU para introducir no linealidad en el modelo.
4. Se agrega una capa de agrupación máxima (max pooling) para reducir la dimensionalidad de las características extraídas.
5. Se aplica una técnica de regularización llamada Dropout para evitar el sobreajuste del modelo. En cada iteración de entrenamiento, se desactiva aleatoriamente un porcentaje de las neuronas para evitar la dependencia excesiva de ciertas características.
6. La arquitectura de la red se aplanada y se agrega una capa completamente conectada (fully connected) con 512 neuronas, seguida de otra capa de Dropout.
7. Finalmente, se agrega una capa de salida con 10 neuronas y una función de activación softmax, que produce la distribución de probabilidad de las clases de salida.
8. El modelo se compila con la función de pérdida de entropía cruzada categórica y el optimizador Adam.
9. Se entrena el modelo utilizando los datos de entrenamiento (x_{train} e y_{train}), con un tamaño de lote de 64 y 10 épocas de entrenamiento.
10. Después del entrenamiento, se evalúa el modelo utilizando los datos de prueba (x_{test} e y_{test}) y se calcula la precisión (accuracy).

el modelo alcanzó una precisión del 78.12% en los datos de prueba.

Resultados y discusión

El modelo de red neuronal convolucional clásico que se proporcionó alcanzó una precisión del 78.12% en el conjunto de pruebas. Este resultado es un indicador del rendimiento del modelo en términos de su capacidad para generalizar a datos no vistos previamente.

Al implementar una CNN cuántica, se podrían explorar diferentes enfoques, como el uso de circuitos cuánticos para simular operaciones de convolución en imágenes RGB, similar al artículo "RGB Image Classification with Quantum Convolutional Ansatz" mencionado anteriormente. Esto permitiría evaluar si la CNN cuántica puede superar al modelo clásico en términos de precisión y eficiencia en la clasificación de imágenes RGB.

En resumen, aunque el modelo de CNN clásica alcanzó una precisión del 78.12%, es necesario implementar una CNN cuántica y realizar comparaciones adicionales para obtener una evaluación más completa y determinar el impacto de la computación cuántica en el rendimiento de la clasificación de imágenes.

REPOSITORIO

<https://github.com/jhanvargas/comparacion-cnn-clasico-cuamico/>

BIBLIOGRAFÍA

- Manuel A. Serrano, Ricardo Pérez-Castillo, and Mario Piattini edited a book titled "Quantum Software Engineering".
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press.